

МСПС | Оценивание плотности и непараметрич. регрессия |

(1)

Для произвольной ф.р. $F(x)$ её оценкой является $F_n(x) = \frac{1}{n} \sum_{i=1}^n I(X_i \leq x)$ — эмпирич. ф.р. А как оценить плотность? Можно истощить. Но хочется чего-то более точного, например, аналога $\frac{d}{dx} F_n(x)$.

Идея состоит в том, чтобы сместить $F_n(x)$ за счёт её свёртки с абс. непрерывным распределением: рассм. сл.в. $Z_n = X + h_n Y$, где Y имеет извест. плот. $q(y)$ и $Y \perp X$, $h_n \rightarrow 0$, а $X \sim F_n$ с плотн. $p(x)$.

Плотность $h_n Y \sim \frac{1}{h_n} q(\frac{z}{h_n}) \Rightarrow p_{Z_n}(z) = \frac{1}{h_n} \int_{\mathbb{R}} q(\frac{z-x}{h_n}) F_n(dx) = \frac{1}{h_n} \int_{\mathbb{R}} q(\frac{z-x}{h_n}) p(x) dx$ (1)

При $h_n \rightarrow 0$ $Z_n \xrightarrow{P} X$, а значит, $p_{Z_n}(z) \rightarrow p(z)$ (при неких допущениях)

Заменяем в ф-ле (1) $F(x)$ на $F_n(x)$ — получим оценку для $p(z)$:

$\hat{p}_n(z) = \frac{1}{h_n} \int_{\mathbb{R}} q(\frac{z-x}{h_n}) F_n(dx) = \frac{1}{n h_n} \sum_{i=1}^n q(\frac{z-X_i}{h_n})$ — оценка Роемблата-Парзена,

или ядерная оценка плотности (плотность $q(z)$ называется ядром)

Теорема Пусть вып. следующие условия:

- 1) $q(y)$ непрерывна и ограничена, при этом $\int_{\mathbb{R}} q^2(y) dy < +\infty$; 2) $h_n \rightarrow 0$ и $h_n \cdot n \rightarrow +\infty$ при $n \rightarrow +\infty$.

Тогда $\hat{p}_n(z) = p_{Z_n}(z) + \frac{z_n(z)}{\sqrt{n} h_n}$, где $p_{Z_n}(z) \rightarrow p(z)$ при почти всех z ,

а $z_n(z) \xrightarrow{d} z(z) \sim N(0, \sigma^2 p(z))$.

Оказывается, что оптим. скорость сходимости в этой теореме достигается при $h_n = C \cdot n^{-\frac{1}{5}}$ (т.е. скорость сходимости — $n^{\frac{4}{5}}$, это неплохо, потому что выше быть не может), а наилучшее с точки зрения сходимости — т.н. Ядро Епанечникова $q^*(y) = \frac{3}{4}(1-y^2) \cdot I(|y| \leq 1)$

Ядро	$q(y)$	Достоинства и недостатки
Епанечникова	$\frac{3}{4}(1-y^2)I(y \leq 1)$	Требование ко всем ядрам: носитель $q(y)$ — конеч. интервал, и на нём ядро 2 раза диффер.
Квадрат.	$\frac{15}{16}(1-y^2)^2 I(y \leq 1)$	Дифф. в точках -1 и 1 , в отличие от ядра Епанеч.
Треугол.	$(1- y)I(y \leq 1)$	Можно быстро производить пересчёт $\hat{p}_n(z)$ при увеличении z .
Гаусса	$\frac{1}{\sqrt{2\pi}} e^{-y^2/2}$	Беск. дифф., но $\hat{p}_n(z)$ вычисл. медленно из-за погрешности экспонент
Прямоуг.	$\frac{1}{2} I(y \leq 1)$	По сути, не ядро, но можно приближ. трапециевидн. От простого peor.

Но скорости сходимости все ядра примерно одинаковы (как и по дисперсии $\hat{p}_n(z)$). Но как всё-таки на практике h_n выбирать?

Пример Выборка размера $n=100$ с плотн. $p(z) = 2(I[0.1; 0.4] + I[0.6; 0.8])$, вычисленные $\hat{p}_n(z)$ для $h_n = 0.02; 0.1; 0.5$



Выводы: выбор малой h_n ведёт к быстро мен. неустойчивой оценке, т.к. $\hat{p}_n(z)$ опирается лишь на небольшое кол-во наблюдений в узкой окрест. z , а слишком большое знач. h_n влечёт чрезмерное сглаживание плотности.

Непараметрич. регрессия

Рассм. модель $Y_i = m(X_i) + \varepsilon_i$. Пусть пока X_i - числа, а не строки, ε_i - н.о.р., $E\varepsilon_i = 0$, $D\varepsilon_i = \sigma^2$. Задача - оценить m .

С помощью метода локал. усреднения имеем:

$\hat{m}(x) = \left(\sum_{i=1}^n w_i(x) \cdot Y_i \right) / \left(\sum_{i=1}^n w_i(x) \right)$, где веса $w_i(x)$ велики для X_i , близких к x и малы для остальных X_i .

Определим $w_i(x)$ с помощью применения ядерных оценок.

Пусть $q(y)$ - ядро, тогда $w_i(x) = q_h(x - X_i)$, где $q_h(y) = \frac{1}{h} q\left(\frac{y}{h}\right)$ и

$h = h_n$ - окно пропускания (bandwidth).

В случае, когда X_i - многомерный, можно взять $w_i(x_1, \dots, x_n) = \prod_{j=1}^n q_h(x_j - X_{ij})$ или $w_i(x) = q_h(\|x - X_i\|)$.

Менее популярн. метод заданная весов - метод Тассера-Мюллера:

$\tilde{w}_i(x) = \int_{X_{(i)}}^{X_{(i+1)}} q_h(x-y) dy$, $-\infty = X_{(0)} < X_{(1)} \leq \dots \leq X_{(n)} < X_{(n+1)} = +\infty$ - вф. ф-я.

Если же заданы веса каким-то другим методом, то получается след.:

$\hat{m}(x) = \frac{\frac{1}{n} \sum_{i=1}^n q_h(x - X_i) \cdot Y_i}{\frac{1}{n} \sum_{i=1}^n q_h(x - X_i)}$ - оценка Макариэ-Ватсона, а снизу, как легко видеть, стоит ядерная оц. плотности, перем. X .

Теорема Пусть X - одномер. и вып. след. условия: 1) $\int |q(y)| dy < +\infty$; 2) $y q(y) \rightarrow 0$ при $y \rightarrow +\infty$; 3) $E(Y^2 | X=x) < +\infty \forall x$; 4) $E(Y | X=x) = m(x)$; 5) $n \rightarrow \infty, h_n \rightarrow 0, n h_n \rightarrow +\infty$.

Тогда $\hat{m}(x) \xrightarrow{P} m(x)$ в \forall точке непр. ф-ции $m(x)$, $p(x)$, и $D(Y|X=x)$.

Если говорить о скорости сходимости $\hat{m}(x)$ к $m(x)$, то наилучшая (по $R(x, h) = E[\hat{m}(x) - m(x)]^2$) скорость сход. достигается на $h_n = \frac{c}{n^{1/5}}$, как и

для оценок плотности.

Оптимизация ширины окна пропускания

Дело в том, что X_i могут быть распределены неравномерно, т.е. где-то много, а где-то пусто. Чтобы оценка регрессии была устойчивой, применяется адаптивное ядро:

$\hat{m}(x) = \frac{\sum_{i=1}^n Y_i q_{h(x)}(x - X_i)}{\sum_{i=1}^n q_{h(x)}(x - X_i)}$, где $h(x)$ можно по-разному выбирать. Популярный способ: $h(x) = \inf \{h: \#\{X_i: |X_i - x| < h\} = k\}$,

т.е. фактор, много k ближайших соседей.

Можно ещё делать так (метод LOO - leave-one-out)

$LOO(h, X) = \sum_{i=1}^n (\hat{m}(x_i, X \setminus \{x_i\}) - y_i)^2 \rightarrow \min_h$, где оценка $\hat{m}(x_i, X \setminus \{x_i\})$ -

- оценка регрессии в т. x_i , построенная по набору observations переменной X , откуда мы исключили значение x_i .

Проблема крайних эффектов

В ординар. случае (т.е. когда X_i - числа) часто наблюдается значит. смещение $\hat{m}(x)$ от истинной зависимости $m(x)$ вблизи миним. и макс. значений X_i (смещение возникает, когда объекты выборки X_i располагаются по одну сторону объекта x - и в многомер. случае такая ситуация возникает чаще).

Решается эта задача так: вместо аппроксимации зависимости в окрест. x числом аппроксимируем её лин. ф-цией, т.е.

$$\sum_{i=1}^n q_h(x) (x - X_i) (y_i - a(x) - b(x)(X_i - x))^2 \rightarrow \min_{a(x), b(x)}$$

Если $b(x) = 0$, то получим эк. Карарае-Вассона, а этот метод назыв. local linear regression model. Если минимизируем ф-л

$$\sum_{i=1}^n q_h(x) (x - X_i) (y_i - a(x) - \sum_{j=1}^d b_j(x) (X_i - x)^j)^2 \rightarrow \min_{a(x), b_j(x)}, \text{ то такой метод}$$

называет. методом локального полинома (local polynomial regression model).

В многомерном случае нужно решать задачу мин. регрессии $y = \vec{a}(x) + B(X - x)$ в каждой точке x , что сопряжено с большими выч. затратами.

Проблема выбросов

Оценка Карарае-Вассона крайне чувствит. к большим ординарным выбросам.

Решается эта проблема так: алгоритм LOWESS (локально взвешенное сплай-вание)

1) Положим $\delta_i = 1 \quad \forall i = 1 \dots n$

2N) Вычислим эк. скользящего контроля (LOO) на каждом объекте:

$$a_i := \hat{m}(x_i, X \setminus \{x_i\}) = \frac{\sum_{j=1, j \neq i}^n y_j \delta_j q_h(x_i) (X_j - X_i)}{\sum_{j=1, j \neq i}^n \delta_j q_h(x_i) (X_j - X_i)}, \quad q - \text{возможно, многомер. ядро.}$$

2N+1) Вычислим коэфф.

$$\delta_i := \{ \bar{q} (a_i - y_i) \}, \quad i = 1 \dots n, \text{ где } \bar{q} - \text{какое-то другое ядро.}$$

Пока коэфф. δ_i не стабилизируются. Тогда, сходимся довольно быстро.

Варианты для ядра $\bar{q}(y)$:

1) Жесткая фильтрация: строится на 2N+1 шаге вариант ред ошибок $\epsilon_{(1)} \leq \dots \leq \epsilon_{(n)}$, где $\epsilon_i = |a_i - y_i|$, тогда $\delta_i := I\{i \leq n - k\}$, т.е. ядро

$$\bar{q}(\epsilon) = I\{\epsilon \leq \epsilon_{(n-k)}\}.$$

2) Мягкая фильтрация: $\bar{q}(\epsilon) = q_0 \left(\frac{\epsilon}{\sigma_{\text{med}}\{\epsilon_i\}} \right)$, где q_0 - квадратич. ядро.