

ММРС | Методы понижения размерности |

Ещё одно решение проблемы мультиколлинеарности состоит в том, чтобы проверить исход. признаки некому линейному преобразованию так, чтобы новые функ. были линейно ^{не}зависимы (и даже ортогональны!), а их число бы уменьшилось.

Метод глав. компонент (PCA)

Пусть есть k исход. признаков $X_1 \dots X_k$ размер. n , расм. матрицу $X = (x_{ij})$, $i=1 \dots n, j=1 \dots k$. Пусть кол-во новых признаков - m , и они образуют матрицу $Z = (z_{ij})$, $i=1 \dots n, j=1 \dots m$, $m < k$.

И нам хочется, чтобы старые признаки по новым как-то восстанавливались, т.е. \exists матрица $U = (u_{ij})$, $i=1 \dots k, j=1 \dots m$:

$\hat{X}_j = \sum_{i=1}^m z_i \cdot u_{ij}$, т.е. \hat{X}_j был как можно ближе к исходному X_j .

Т.е. хотим решить задачу $\Delta^2(Z, U) = \sum_{i=1}^n \sum_{j=1}^k \|X_{ij} - \hat{X}_{ij}\|^2 = \sum_{j=1}^k \|X_j - \hat{X}_j\|^2 = \|ZU^T - X\|^2 \xrightarrow{\min_{Z, U}} \min_{Z, U}$. Пусть Z и U равна m , т.е. невырожд. норма Фробениуса

Теорема Если $m \leq rk(X)$, то минимум $\Delta^2(Z, U)$ достигается, когда столбцы матрицы U есть собств. вектора $X^T X$, соотв. m максимальным собств. значениям. При этом $Z = X \cdot U$, матрицы U и Z ортогональны.

Св-ва 1) Матрица U ортонормирована: $U^T U = I_m$

2) Матрица $Z^T Z = \Lambda = \text{diag}(\lambda_1 \dots \lambda_m)$, где $\lambda_1 \geq \dots \geq \lambda_m$ - m максимал. собств. значений матрицы $X^T X$.


3) $U \Lambda = X^T X U$, $Z \Lambda = X X^T Z$

4) $\|ZU^T - X\|^2 = \|X\|^2 - \text{tr} \Lambda = \sum_{j=m+1}^k \lambda_j$

Из св-ва 4) вытекает, что тем меньше $E_m = \frac{\sum_{j=m+1}^k \lambda_j}{\sum_{j=1}^k \lambda_j}$, тем лучше новые признаки приближ. старые.

Поэтому вводятся эффектив. размерность выборки: $\tilde{m} := \min_m \{E_m < \epsilon\}$.

Кол-во новых признаков можно считать ~~связью~~ с помощью критерия "круглого склона":



Находим $m+1: E_m \gg E_{m+1}$
Вкат. эффектив. размер. берём $m+1$.

Решение задачи лин. регрессии в новых признаках:

заменяем X на $Z \cdot U^T$, получ. след. задачу: $\|Y - ZU^T \theta\|^2 = \|Y - Z \beta\|^2 \xrightarrow{\min_{\beta}}$

Тогда $\hat{\beta} = D^{-1} V^T Y$, $\hat{\theta} = U D^{-1} V^T Y = \sum_{j=1}^m \frac{1}{\sqrt{\lambda_j}} u_j (V_j^T Y)$, где $D = \sqrt{\Lambda}$,

а V - св-ва с сингулярным разложением, теперь проверим о нём.

МСПС | Метод понижения размерности

(2)

Сингулярное разложение (SVD)

Матрица размера $n \times k$ ^{$n > k$} представлена в виде $X = VDU^T$, где

- 1) $n \times n$ матрица V ортогональна, $V^T V = I_n$, её столбцы - соб. векторы матрицы XX^T
- 2) $n \times k$ матрица D диагональна, $D = \text{diag}(\sqrt{\lambda_1}, \dots, \sqrt{\lambda_k})$, где λ_j - соб. значения матриц $X^T X$ и XX^T .
- 3) $k \times k$ матрица U ортонорм., $U^T U = I_k$, столбцы u_j - соб. векторы матрицы $X^T X$.

Для решения задачи мин. квадратов восп. так:

$$(X^T X)^{-1} X^T Y = (U^T V^T V D U)^{-1} U^T V^T Y = U^T D^{-1} V^T Y = \sum_{j=1}^k \frac{1}{\sqrt{\lambda_j}} u_j (V_j^T Y)_j$$

псевдообр. матрица I_n $\text{diag}(1, \dots, 1, 0, \dots, 0)$

$$\hat{X\theta} = (V D U^T) U^T D^{-1} V^T Y = V V^T Y, \text{ ну и т.д.}$$

Для регрессии решение будет таким: $\hat{\theta}_{\text{ridge}} = \sum_{j=1}^k \frac{\sqrt{\lambda_j}}{\lambda_j + \tau} u_j (V_j^T Y)_j$

Кстати, регуляризация сокращает эффектив. размерность (а мы знаем, что это ~~приводит~~ к тому, что модель более устойчива), т.к.

$$\text{tr}(X(X^T X + \tau I_n)^{-1} X^T) = \text{tr}(\text{diag}(\frac{\lambda_j}{\lambda_j + \tau})) = \sum_{j=1}^k \frac{\lambda_j}{\lambda_j + \tau} < n \quad (\text{это когда мы все } \sum \lambda_j = n \text{ средним})$$

Связь сингуляр. разложения и метода глав. компонент

Если $k = n$ (т.е. кол-во признаков не уменьшаем), то $Z = V \cdot \sqrt{\Lambda}$.

Замечание Главные компоненты вычисляются по $X^T X$ и поэтому зависят от масштаба признаков \Rightarrow перед их вычислением данные надо нормировать.

Еще свойства метода глав. компонент

- а) Проекции объектов на 1 глав. компоненту c_1 (соотв. соб. знач. λ_1 , считаем, что $\lambda_1 \geq \lambda_2 \dots$) имеют наибольшую вар. дисперсию сфера проекций на всевозможные направл. d в пр-ве \mathbb{R}^k .
Далее, $\forall j \geq 2$ c_j - j -тая глав. компонента, т.е. соб. вектор матрицы $X^T X$ с λ_j соб. знач. λ_j , - направление с наибольшей вар. дисперсией проекций объектов сферы направл., \perp векторам $c_1 \dots c_{j-1}$.

- б) На пр-ве св-ве основан степенной метод вычисления глав. компонент

Пусть есть произв. симм. матрица A , и её соб. числа $|\lambda_1| > |\lambda_2| \geq \dots \geq |\lambda_n|$
 c_1 - соб. вектор, соотв. λ_1 и для нек. $x_0 \in \mathbb{R}^n$ $c_1^T \cdot x_0 \neq 0$.

$$\text{Положим } x_{i+1} = A x_i$$

Теорема $t_{i+1} = \frac{x_i^T x_{i+1}}{|x_i|^2} \rightarrow \lambda_1$ со скоростью геометр. прогрессии со знаменателем $\gamma = |\lambda_2/\lambda_1| < 1$

Док-во: Пусть $x_0 = v_1 \cdot c_1 + \dots + v_n \cdot c_n$. Поскольку $A c_i = \lambda_i c_i$, то
 $A^i x_0 = x_i = \lambda_1^i v_1 c_1 + \dots + \lambda_n^i v_n c_n = \lambda_1^i (v_1 c_1 + \delta_i)$, где $\delta_i = v_2 (\lambda_2/\lambda_1)^i c_2 + \dots$,

$$\text{причем } |\delta_i| = O(\gamma^i) \xrightarrow{i \rightarrow +\infty} 0$$

Замечание Если $|\lambda_1| > 1$, то $|x_i| \rightarrow +\infty$, если $|\lambda_1| < 1$, то $|x_i| \rightarrow 0$ при $i \rightarrow \infty$

Поэтому на кардан мале надо x_i нормировать.

Если же вдруг $c_1^T x_0 = 0$ (бывает раньше не знаем c_1), то стоит рассмотреть нек-е другие векторы - на одном из них $c_1^T x_{0i} \neq 0$.

МСПС (Методы понижения размерности)

(3)

Алгоритм выч. λ_k и c_k (в предположении, что λ_j и c_j известны $\forall j \leq k-1$)

- 1) $i=0$, $t_0=0$, выбираем произвол. $x_0 \in \mathbb{R}^n$
- 2) Ортогонализир. x_i по векторам c_1, \dots, c_{k-1} (если $k=1$, то пропуск. этот шаг): $y_i = x_i - (c_1^T x_i) c_1 - \dots - (c_{k-1}^T x_i) c_{k-1}$
- 3) Нормируем y_i : $e_i = y_i / |y_i|$
- 4) Вычислим $x_{i+1} = A e_i$ и $t_{i+1} = e_i^T x_{i+1}$
- 5) Нормируем x_{i+1} : $z_{i+1} = x_{i+1} / |x_{i+1}|$
- 6) Если $|t_{i+1} - t_i| \leq \epsilon$, то положим $\lambda_k = t_{i+1}$, $c_k = z_{i+1}$ и закончим процесс. Если нет, то выбираем $x_{i+1} := z_{i+1}$, $i := i+1$ и возвращ. к шагу 2.

Собственно, сингулярное разложение сводится к QR-разложению матрицы $A = QR$, где Q - ортогон., R - верхнетреуг., которое, в свою очередь, получается похожей процедурой (методом ортогонал. Трама-Шмидта). А этот алгоритм нужен в том случае, если мы не хотим сразу все глав. компоненты искать, а только первые несколько.

Замечание Понять размерность можно и с помощью сингулярного разложения, взяв в кал. новую ф-ва $m < k$ соб. векторов матрицы $X^T X$

МНС | Линейные методы понижения размерности |

(7)

Метод главных компонент - это классика, но слетка прошлый век. Его недостатки:

- 1) Если $|\lambda_i| = |\lambda_{i+1}|$ для какого-то i , то ^{линейной} метод не работает.
- 2) Метод PCA способен породить только лин. подпространства исход. пр-ва, которые "объясняют" данные с высокой точностью. На практике поверхности, вдоль кот. располагаются данные, может быть существенно отлич. от линейной.
- 3) PCA явл. инвариантным к повороту коорд. в пр-ве признаков \Rightarrow \Rightarrow восстановление значений признаков может быть неоднозначным. Иногда это убивает весь метод.

Многомер. шкалирование (локальное линейное погружение, LLE)

Цель, как и в ∇ методе пониж. размерности, минимизир. некое Φ -функционала, выражающее суммарное расхождение между заданными расст. между объектами d_{ij} (где $d_{ij} = \rho(x_i, x_j)$, $\{x_i\}$ - объекты, ну или признаки) и расст. δ_{ij} между образами объектов в пр-ве небольшой размер. Например, $F_0 = \sum_{i,j} (\delta_{ij} - d_{ij})^2$ - стандарт. метод многомер. шкалирования. Или метод Саммонса $F_1 = \frac{1}{\sum_{i,j} d_{ij}} \sum_{i,j} \frac{(\delta_{ij} - d_{ij})^2}{d_{ij}}$ (более точно передает небольшие различия и менее точно - большие, т.к. при отображ. больших расстояний допустимы большие ошибки)

Теперь как искать $\min F$? Надо задать некое нач. конфигурацию:

- а) можно сфронт. наши данные в некое пр-во размер. m
- б) или m глав. комп. взвесь, в) или m слуг. векторов

Метод градиентных спусков

1) Определим \vec{p}_t в пр-ве $\mathbb{R}^{n \times m}$ по Φ -лам: $\vec{x}_t \in \mathbb{R}^{n \times m}$

$$p_1 = -g_1, p_t = -g_t + \beta_t \cdot p_{t-1} \text{ при } t \geq 2, \text{ где } g_t = \left(\frac{\partial F}{\partial x_{11}}, \dots, \frac{\partial F}{\partial x_{nm}} \right), p_{t-1} - \text{направл. на пред. шаг, } \beta_t = \frac{\|g_t\|^2}{\|g_t - g_{t-1}\|^2}$$

2) Производится перемещ. до точки \min по выст. направлению:

$$x_{t+1} = x_t + \alpha_t p_t, \text{ где } F(x_t + \alpha_t p_t) = \min_{\alpha} F(x_t + \alpha p_t). \text{ Можно брать и } \alpha_t = \frac{(x_t - x_{t-1})^T (g_t - g_{t-1})}{\|g_t - g_{t-1}\|^2}$$

Если $\|g_{t+1}\| \leq \epsilon$, где ϵ мало, то заканчиваем.

Замечания: 1) Почему просто не взять $p_t = -g_t$? (Метод наискорейшего спуска)

Плохо работает, если Φ -функ. - "овраг", не останавливается.

$$2) \frac{\partial F}{\partial x_{ie}} = \frac{2}{c_i} \sum_{j=1, j \neq i} \left(\frac{1}{d_{ij}} - \frac{1}{\delta_{ij}} \right) (x_{ie} - x_{je}), \text{ если метрика евклидова}$$

3) Метод стохастич. градиента: случайно выбираем произвольный $\frac{\partial F}{\partial x_{ij}}$ и по нему идём. Сходится медленнее, зато не требует больших выст. затрат.

4) Метод Саммонса хорош тем, что позволяет работать с матрицами ранжир. с пропусками. Для этого суммируем в F_1 только по тем парам объектов, по кот. пропусков нет. Хорошо работает, даже если доля пропусков 30%.

МКСН | Методы на понижение размерности (нелинейные)

(2)

Метод t-SNE.

Разработан в 2008. Намного лучше PCA, но работает медленнее.

Пусть $\mathcal{X} \subset \mathbb{R}^k$ - набор из n векторов признаков наших вход. объектов.

Пусть объекты \mathcal{X} порождаются некоторым отображением: $\exists f: \mathbb{R}^d \rightarrow \mathbb{R}^k$ - латент.

$\forall x \in \mathcal{X} \exists z^* \in \mathbb{R}^d: x = f(z^*) + \varepsilon(z^*)$, где $\varepsilon(z^*)$ - вектор с конеч. матрицей ковариации. d будем называть эфф. размерностью \mathcal{X} . Но, где, d не знаем. Будем искать поиск репр. в пр-ве \mathbb{R}^e , $e < k$.

Рассм. выборку из объектов $x_1, \dots, x_n \in \mathcal{X}$, и $d_{ij} = P(x_i, x_j)$ и $\delta_{ij} = Q(x_i, x_j)$ - вер. меры схожести объектов в \mathbb{R}^k и \mathbb{R}^e .

$$d_{ij} = \frac{\exp(-\frac{1}{2\sigma_i^2} \|x_i - x_j\|^2)}{\sum_{m \neq i} \exp(-\frac{1}{2\sigma_i^2} \|x_i - x_m\|^2)}, \quad \# d_{ij} = \frac{d_{ij} + d_{ji}}{2n};$$

$$\delta_{ij} = \frac{(1 + \|z_i - z_j\|^2)^{-1}}{\sum_{m \neq i} (1 + \|z_i - z_m\|^2)^{-1}}, \quad \delta_{ii} = 0. \quad z_i - \text{образы } x_i \text{ в } \mathbb{R}^e.$$

σ_i - это bandwidth, и выбирается соответственно.

Далее минимизируем $F(d_{ij}, \delta_{ij})$, и $z_{\min} = \arg \min_{z \in \mathbb{R}^{n \times e}} F(d_{ij}, \delta_{ij})$, где

$$F(d_{ij}, \delta_{ij}) = \sum_{i \neq j} d_{ij} \cdot \ln \frac{d_{ij}}{\delta_{ij}} - \text{расстояние Кульбака-Лейблера.}$$

Ну и задача решается градиентными методами.